

TRABALHO PRÁTICO 01 — CLASSIFICAÇÃO KNN

GCC128 – Inteligência Artificial — Universidade Federal de Lavras
Pyêtro Augusto Malaquias e Matheus Gomes Monteiro

1. Metodologia

Foram desenvolvidos dois classificadores KNN sobre a base Iris (150 amostras, 4 atributos e 3 classes). O primeiro consiste em uma implementação do zero, na qual a distância euclidiana é calculada manualmente entre a amostra de teste e todos os padrões de treinamento, as distâncias são ordenadas para a seleção dos k vizinhos mais próximos e a classe é definida por voto majoritário. A matriz de confusão e as métricas de precisão, revocação e acurácia foram igualmente implementadas de forma manual, a partir da diagonal e das somas de linhas e colunas da matriz. O segundo classificador emprega a classe `KNeighborsClassifier` da biblioteca Scikit-learn.

A base foi particionada em 60% para treinamento (90 amostras) e 40% para teste (60 amostras). A semente do gerador pseudoaleatório foi fixada em 42, de modo que ambas as implementações recebem exatamente os mesmos conjuntos, o que assegura uma comparação justa e a reprodutibilidade dos resultados aqui apresentados. A matriz de confusão e as métricas são plotadas graficamente pela aplicação, sob a forma de mapa de calor e de gráfico de barras por classe. Os tempos de execução, por serem sensíveis a variações do ambiente, foram obtidos pela média de dez execuções precedidas de uma execução de aquecimento.

2. Resultados

k	Acurácia (do zero)	Acurácia (Sklearn)	Precisão média	Revocação média	Tempo (do zero) média ± desvio	Tempo (Sklearn) média ± desvio	Predições divergentes
1	95,00%	95,00%	0,9404	0,9472	19,25 ± 0,58 ms	1,43 ± 0,08 ms	0 / 60
3	96,67%	96,67%	0,9617	0,9617	19,63 ± 0,71 ms	1,48 ± 0,07 ms	0 / 60
5	98,33%	98,33%	0,9861	0,9762	20,60 ± 1,29 ms	1,46 ± 0,05 ms	0 / 60
7	96,67%	96,67%	0,9617	0,9617	19,67 ± 1,07 ms	1,52 ± 0,08 ms	0 / 60

Tabela 1 — Métricas obtidas pelas duas implementações para cada valor de k . Os tempos correspondem à média e ao desvio padrão de 10 execuções, após aquecimento.

real \ predito	setosa	versicolor	virginica
setosa	23	0	0
versicolor	0	13	1
virginica	0	0	23

Tabela 2 — Matriz de confusão para $k = 5$, idêntica nas duas implementações. O único erro consiste em uma amostra de *versicolor* classificada como *virginica*.

3. Análise de desempenho

No que diz respeito à qualidade da classificação, as duas implementações produziram matrizes de confusão e métricas rigorosamente idênticas em todos os valores de k testados, sem nenhuma predição divergente nas 60 amostras de teste. Tal resultado valida a corretude da implementação desenvolvida do zero, uma vez que reproduzir exatamente a saída de uma biblioteca consolidada constitui uma forma objetiva de verificação. Cabe observar que ambas as implementações resolvem eventuais empates no voto majoritário pelo menor rótulo de classe, o que contribui para a convergência dos resultados.

A diferença relevante entre as abordagens está no custo computacional. Nos testes realizados, a implementação da biblioteca apresentou tempo de execução consistentemente inferior ao da implementação própria, da ordem de uma dezena de vezes menor, com desvios padrão reduzidos ao longo das repetições. Convém ressaltar que medidas de tempo dependem do ambiente de execução, de modo que a comparação deve ser interpretada como uma diferença de ordem de grandeza e não como um fator exato. A origem da diferença é estrutural: a versão desenvolvida do zero percorre todos os padrões de treinamento em laço explícito para cada amostra de teste, com custo $O(n \cdot m)$ por predição, ao passo que a biblioteca emprega operações vetorizadas em código compilado associadas a uma estrutura de índice espacial. Com o parâmetro `algorithm` no valor padrão, o Scikit-learn selecionou a KD-Tree neste conjunto de dados, embora tal escolha seja automática e possa variar conforme as características dos dados e a versão da biblioteca. Na base Iris a diferença é irrelevante em termos absolutos, mas tornar-se-ia proibitiva em conjuntos de dados de maior porte.

Quanto à influência do hiperparâmetro, $k = 5$ apresentou a melhor taxa de reconhecimento, de 98,33%. Com $k = 1$ obteve-se a menor acurácia, 95,00%, o que se explica pelo fato de a decisão depender de um único vizinho, tornando o classificador sensível a ruído. Valores maiores de k suavizam a fronteira de decisão, porém $k = 7$ já registrou leve queda, indicando perda de flexibilidade na discriminação entre classes. A classe *setosa* foi classificada corretamente em todos os cenários, por ser linearmente separável das demais, enquanto os erros concentraram-se entre *versicolor* e *virginica*, cujas amostras se sobrepõem no espaço de atributos.

4. Conclusão

A implementação do algoritmo KNN desenvolvida do zero mostrou-se funcionalmente equivalente à da biblioteca Scikit-learn, o que confirma a compreensão dos fundamentos do método: cálculo de distância, seleção de vizinhos, voto majoritário e derivação das métricas a partir da matriz de confusão. Por outro lado, a comparação evidencia as razões pelas quais bibliotecas otimizadas são preferíveis em aplicações práticas, pois entregam o mesmo resultado com uma fração do custo computacional. Conclui-se, portanto, que a implementação manual possui valor essencialmente didático, ao passo que o uso em produção requer as versões otimizadas.