

TRABALHO PRÁTICO 02 — AGRUPAMENTO COM K-MEANS

GCC128 – Inteligência Artificial — Universidade Federal de Lavras
Pyêtro Augusto Malaquias e Matheus Gomes Monteiro

1. Metodologia

Desenvolveu-se uma aplicação de aprendizado não supervisionado com o algoritmo K-Means sobre a base Iris (150 amostras, 4 atributos, 3 espécies). O algoritmo foi implementado do zero, contemplando a inicialização dos centróides, o ciclo de atribuição dos pontos ao centróide mais próximo, a atualização dos centróides pela média aritmética dos pontos de cada grupo e o critério de parada por estabilização. As métricas WCSS e Silhouette também foram implementadas manualmente. Os rótulos das espécies não foram fornecidos ao algoritmo em nenhum momento, sendo empregados exclusivamente na análise final dos agrupamentos.

Para a inicialização adotou-se o k-means++, no qual o primeiro centróide é sorteado uniformemente e os demais são sorteados com probabilidade proporcional ao quadrado da distância ao centróide mais próximo já escolhido. Como o K-Means converge apenas para mínimos locais, cada valor de K foi executado dez vezes, retendo-se a solução de menor WCSS. A semente do gerador pseudoaleatório foi fixada em 42, assegurando a reprodutibilidade dos resultados.

Sobre a padronização. A padronização por Z-score centra cada atributo na média e o escala pelo desvio padrão, impedindo que atributos de maior magnitude dominem a distância euclidiana. Na base Iris, contudo, os quatro atributos já se encontram na mesma unidade (centímetros) e na mesma ordem de grandeza, de modo que a padronização não é obrigatória. Optou-se, portanto, por executar o experimento nos dois cenários — dados brutos e padronizados — a fim de mensurar o efeito dessa decisão em vez de presumi-lo.

2. Resultados

K	WCSS (brutos)	Silhouette (brutos)	WCSS (padronizados)	Silhouette (padronizados)
2	152,348	0,6810	222,362	0,5818
3	78,851	0,5528	139,820	0,4599
4	57,256	0,4975	114,505	0,4133
5	46,446	0,4887	90,808	0,3455
6	39,040	0,3648	80,860	0,3354
7	34,386	0,3532	71,620	0,3286
8	30,187	0,3575	63,103	0,3217
9	28,073	0,3151	54,121	0,3489
10	26,192	0,3237	47,498	0,3596

Tabela 1 — WCSS e Silhouette Score para cada valor de K nos dois cenários de pré-processamento.

3. Escolha do número de clusters




Figura 1 — Método do Cotovelo nos dois cenários. A inflexão ocorre em K = 3 em ambos.

O WCSS decresce monotonicamente com o aumento de K, chegando a zero quando K iguala o número de amostras; o critério não é, portanto, o menor valor absoluto, e sim o ponto de retorno decrescente. Nos dados brutos, a passagem de K = 2 para K = 3 reduz o WCSS em 48,2%, ao passo que as transições seguintes reduzem 27,4% e 18,9%. A inflexão é nítida em K = 3, e o mesmo padrão se repete no cenário padronizado.

O Silhouette Score, entretanto, atinge seu máximo em K = 2 nos dois cenários (0,6810 e 0,5818). A discordância entre os critérios não constitui erro: o cotovelo busca o ponto de saturação da compactação intra-grupo, enquanto a silhueta premia grupos bem separados entre si. Na base Iris uma das espécies encontra-se isolada, enquanto as outras duas se sobrepõem; separá-las implica traçar uma fronteira no interior de uma região densa, o que reduz a silhueta ainda que a partição seja correta do ponto de vista biológico. Esse resultado evidencia que as métricas internas descrevem a geometria dos dados, não a estrutura semântica de interesse. Adotou-se K = 3, com base no Método do Cotovelo e no conhecimento do domínio.

4. Visualização dos agrupamentos

Como a base possui quatro atributos, empregou-se a Análise de Componentes Principais (PCA) para projetar os dados em duas dimensões. A técnica é adequada ao caso porque as duas primeiras componentes concentram 97,8% da variância total, preservando a estrutura de distâncias sobre a qual o K-Means opera.




Figura 2 — Projeção PCA. O primeiro painel exibe as espécies reais apenas como referência visual; elas não participaram do agrupamento.

A comparação visual torna explícito o efeito do parâmetro. Com $K = 2$, o grupo isolado é corretamente separado, porém as duas espécies sobrepostas são fundidas em um único agrupamento. Com $K = 3$, a partição aproxima-se das espécies reais, com erros restritos à região de fronteira. Com $K = 4$, um grupo coeso é dividido ao meio sem que exista separação correspondente nos dados, ilustrando que o algoritmo cumpre o K imposto independentemente da estrutura subjacente.

5. Análise dos grupos encontrados

espécie \ grupo	grupo 0	grupo 1	grupo 2
setosa	0	50	0
versicolor	48	0	2
virginica	14	0	36

Tabela 2 — Matriz de contingência para $K = 3$ sobre os dados brutos. A numeração dos grupos é arbitrária, pois o algoritmo apenas particiona.

A espécie *setosa* foi isolada integralmente em um único grupo, sem contaminação, comportamento coerente com sua separabilidade linear em relação às demais. As espécies *versicolor* e *virginica* foram majoritariamente separadas, concentrando-se os erros na região de sobreposição: 2 amostras de *versicolor* e 14 de *virginica* foram alocadas no grupo predominante da outra espécie. O índice ARI, que mede a concordância entre partições corrigida pelo acaso, atingiu 0,7302. A análise da silhueta individual reforça o diagnóstico: o grupo correspondente à *setosa* apresenta silhueta média de 0,7981, enquanto os dois grupos sobrepostos ficam em 0,4173 e 0,4511, sem nenhuma amostra com valor negativo.

6. Efeito da normalização

Ambos os cenários conduzem ao mesmo K pelo Método do Cotovelo, porém produzem partições de qualidade distinta. Nos dados brutos, o agrupamento apresenta silhueta de 0,5528 e ARI de 0,7302; após a padronização, esses valores caem para 0,4599 e 0,6201, respectivamente. A padronização, portanto, degradou o resultado nesta base.

A explicação reside na natureza dos atributos. Padronizar atribui peso idêntico a todos eles, e na Iris o comprimento e a largura da pétala são justamente os atributos que discriminam as espécies, ao passo que a largura da sépala discrimina pouco. Ao equalizar as escalas, a padronização amplifica a contribuição do atributo menos informativo e dilui a dos mais relevantes. Conclui-se que a padronização não constitui etapa automática: é indicada quando os atributos se encontram em unidades ou ordens de grandeza distintas, mas pode suprimir o sinal de interesse quando as diferenças de dispersão carregam informação legítima, como no caso presente.

7. Limitações do K-Means

Os experimentos evidenciaram limitações características do algoritmo. O número de grupos é parâmetro de entrada e não é descoberto pelo método, como demonstrou a execução com $K = 4$, que fragmentou um grupo coeso. A convergência ocorre apenas para mínimos locais, dependendo da inicialização — limitação mitigada, mas não eliminada, pelo `k-means++` e pelas dez execuções por K . Por empregar distância euclidiana até centróides, o método pressupõe grupos aproximadamente globulares e de tamanhos semelhantes, sendo inadequado a estruturas alongadas, aninhadas ou anelares. Mostrou-se ainda sensível à escala dos atributos, conforme discutido na seção anterior, e é sensível a outliers, uma vez que o centróide é uma média. Por fim, todo ponto é obrigatoriamente atribuído a algum grupo, inexistindo a categoria de ruído oferecida por métodos baseados em densidade, como o DBSCAN.

8. Conclusão

O algoritmo K-Means foi implementado do zero, incluindo inicialização `k-means++`, ciclo de atribuição e atualização, critério de convergência e as métricas WCSS e Silhouette. A verificação contra a implementação do Scikit-learn produziu valores idênticos de WCSS e Silhouette e concordância total entre as partições (ARI igual a 1,0), o que confirma a correteza do desenvolvimento. O Método do Cotovelo indicou $K = 3$ de maneira consistente, coincidindo com o número real de espécies, enquanto a silhueta favoreceu $K = 2$ — discordância que ilustra a importância de não delegar a decisão a uma única métrica em problemas não supervisionados. O agrupamento final recuperou uma das espécies integralmente e separou as demais com erros concentrados na região de sobreposição, e o teste da padronização mostrou que o pré-processamento deve ser justificado pelos dados, e não aplicado por hábito.

Vídeo de apresentação: <https://drive.google.com/file/d/1eJa0A75mcm3XpGQTdaITXVSNr5iy4s7/view?usp=sharing>