

TRABALHO PRÁTICO 03 — CLASSIFICAÇÃO COM MLPCLASSIFIER

GCC128 – Inteligência Artificial — Universidade Federal de Lavras
Pyêtro Augusto Malaquias e Matheus Gomes Monteiro

1. Metodologia

Aplicou-se o `MLPClassifier` do Scikit-learn às bases Iris (150 amostras, 4 atributos) e Wine (178 amostras, 13 atributos), ambas com 3 classes. A rede empregou uma camada oculta de 100 neurônios, ativação ReLU e otimizador Adam, com `max_iter` elevado a 2000 para assegurar a convergência. A partição foi de 70% para treino e 30% para teste, estratificada, com semente fixa em 42 — de modo que o MLP e o KNN recebessem exatamente as mesmas amostras.

Os atributos foram padronizados dentro de um `Pipeline`, o que garante que média e desvio padrão sejam estimados apenas no conjunto de treino. A decisão foi verificada empiricamente: repetindo o treino com dez sementes na base Wine, a rede sem padronização obteve acurácia média de 74,81% com desvio padrão de 25,52%, chegando a 27,78% no pior caso, ao passo que com padronização alcançou 98,15% com desvio de apenas 1,17%. O atributo *proline* varia em mais de 1.400 unidades enquanto outros variam menos de 1, e essa disparidade desestabiliza o gradiente. Na Iris, cujos atributos estão todos em centímetros, a rede opera bem em ambos os casos.

2. Resultados

Base	Classificador	Acurácia	Precisão (macro)	Revocação (macro)
Iris	MLPClassifier	91,11%	0,9155	0,9111
Iris	KNN (k = 5)	91,11%	0,9298	0,9111
Wine	MLPClassifier	100,00%	1,0000	1,0000
Wine	KNN (k = 5)	94,44%	0,9444	0,9524

Tabela 1 — Métricas dos dois classificadores nas duas bases, sobre as mesmas partições de teste.

	Iris — MLP	Iris — KNN	Wine — MLP	Wine — KNN
Classe 1	15 / 0 / 0	15 / 0 / 0	18 / 0 / 0	18 / 0 / 0
Classe 2	0 / 14 / 1	0 / 15 / 0	0 / 21 / 0	0 / 18 / 3
Classe 3	0 / 3 / 12	0 / 4 / 11	0 / 0 / 15	0 / 0 / 15

Tabela 2 — Matrizes de confusão, apresentadas em linhas (classe real) com as três contagens preditas separadas por barras. As matrizes completas, em mapa de calor, estão no notebook.

3. Análise comparativa entre o KNN (TP01) e o MLPClassifier

Na base Iris os dois classificadores empataram em acurácia, com 91,11%. O resultado é coerente com a natureza do problema: são apenas quatro atributos e uma das classes é linearmente separável das demais, de modo que a fronteira de decisão exigida é simples. A capacidade adicional da rede neural não encontra estrutura suplementar a explorar, e o KNN, que apenas compara distâncias, já resolve satisfatoriamente. Ambos concentram os erros na mesma região, a fronteira entre *versicolor* e *virginica*, comportamento também observado no Trabalho Prático 01. A distinção entre eles aparece apenas na distribuição dos erros: o MLP obteve precisão macro ligeiramente inferior, 0,9155 contra 0,9298.

Na base Wine, ao contrário, o MLP superou o KNN de forma clara, classificando corretamente todas as 54 amostras de teste, contra 94,44% do KNN, que confundiu três amostras da segunda classe. A diferença se explica pela dimensionalidade: com treze atributos, a classe decorre de combinações entre eles, e não da proximidade direta no espaço original. A rede aprende essas combinações nos pesos da camada oculta, ao passo que o KNN depende de que amostras da mesma classe permaneçam próximas — propriedade que se degrada à medida que a dimensão aumenta.

Cabe registrar ainda uma diferença de natureza entre os métodos. O KNN é baseado em instâncias: não possui fase de treinamento, o custo concentra-se na classificação e o modelo é o próprio conjunto de dados armazenado. O MLP constrói um modelo paramétrico durante o treino — 523 iterações na Iris e 264 na Wine — e, uma vez treinado, classifica de modo praticamente imediato. Em contrapartida, o KNN possui essencialmente um hiperparâmetro, enquanto o MLP exige a definição de arquitetura, função de ativação, otimizador e taxa de aprendizado, o que o torna mais flexível e simultaneamente mais trabalhoso de ajustar.

4. Conclusão

O `MLPClassifier` foi aplicado corretamente às duas bases, com as matrizes de confusão e as métricas de precisão, revocação e acurácia apresentadas para cada uma. A comparação com o KNN do Trabalho Prático 01, executada sobre partições idênticas, indica que o ganho da rede neural não é uniforme: em problemas de baixa dimensão e fronteiras simples, como a Iris, um método mais elementar entrega resultado equivalente com muito menos configuração; em bases com mais atributos e classes definidas por combinações entre eles, como a Wine, a rede obtém vantagem significativa. Conclui-se que a escolha do classificador deve considerar as características do problema, e não uma suposta superioridade intrínseca de modelos mais complexos.

Vídeo de apresentação: <https://drive.google.com/file/d/1eEwNQ3uJIM0UQ1xQs3mw9czmKX-vN0mB/view?usp=sharing>